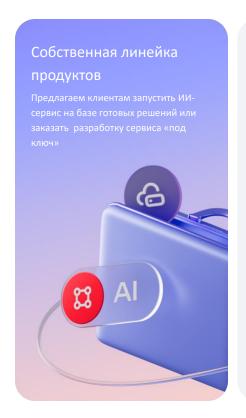
Анализ текста на страже жизни. Собираем текстовый датасет о том, как говорят о суициде

Игорь Буянов Ведущий разработчик NLP IMP MTS AI



О КОМПАНИИ МТЅ АІ



Используем последние научные достижения

• Прикладные исследования

Открытия в аналитике и синтезе речи, новых методах разметки, развитие ML/LLM

Фундаментальные исследования

Статьи в научных журналах Tier 1

400+ экспертов в сфере ИИ

Объединили ученых, разработчиков технических экспертов,

предпринимателей и инвесторов, чтобы

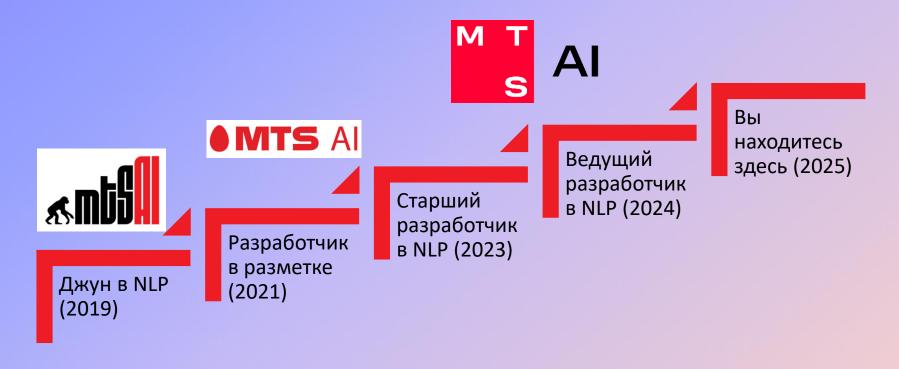


R&D-центр

Разрабатываем собственные продукты и решения для бизнеса на основе ИИтехнологий

- Машинное обучение
- Компьютерное зрение
- Обработка естественного языка
- Генеративный ИИ

Обо мне



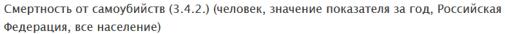
Про проблему суицида

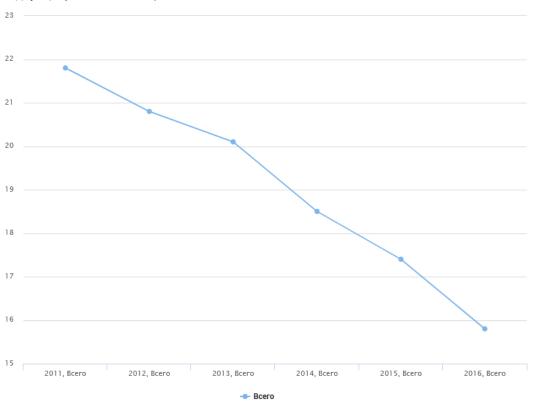
Цифры



https://www.demoscope.ru/weekly/2020/0869/suicide.php

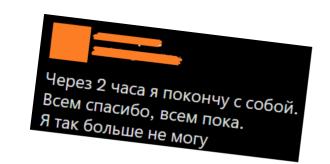
Цифры





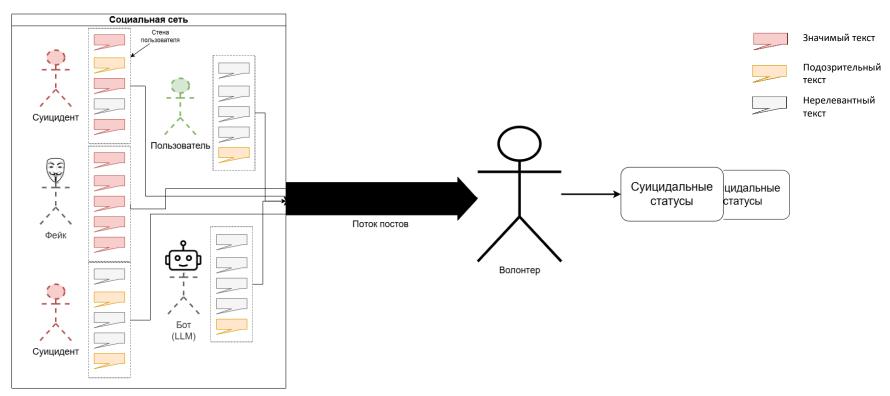
Социальные сети как эмоциональный клапан

Я чувствую после вчерашнего приёма психиатра, как мне часто становится трудно дышать. Я вспоминаю, как 6 лет назад я буквально задыхалась и захлебывалась в рыданиях постоянно. Сейчас такого нет. Зато дошя другого



Сейчас лежу в кроватке и меня безумно тошнит Бабушка уже перекормила, хотя я тут второй день இТОШНИТ ОТ НЕНАВИСТИ К СЕБЕ ЛАЛНО

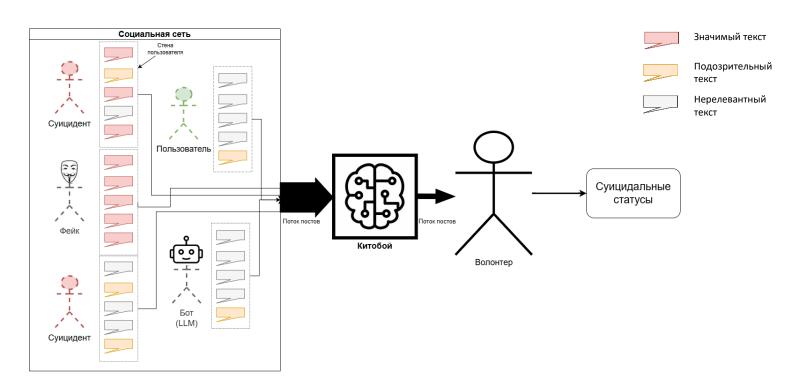
Модель



Проблема

- Десятки подозрительных профилей в неделю обрабатывались волонтерами в 2021 году.
- От десятков до тысяч постов может быть на странице профиля.
- 200 постов в час может обработать человек без учета времени на решение о суицидальном статусе.
- 40 из 200 постов содержат целевую информацию.

Модель

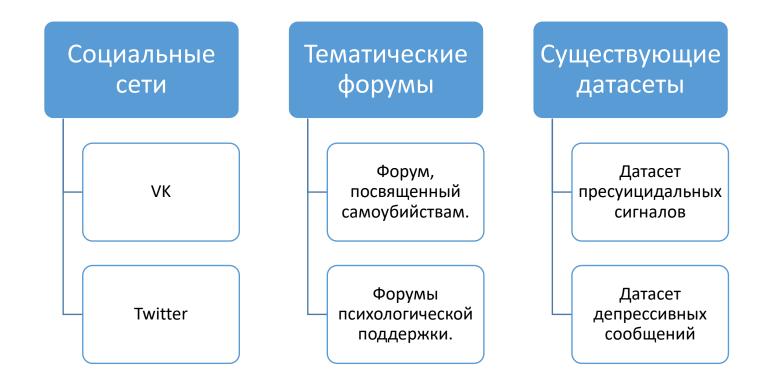


Мы не определяем по тексту Х.

Мы определяем тексты, описывающие Х.

Про данные

Источники данных



Обогащение признаками

- Количество слов
- Эмоции
- Сентимент
- Пресуицидальный сигнал
- Наличие личных местоимений
- Признаки ролей
 - Брачные
 - Родительские
 - Семейные
 - Дружеские и любовные

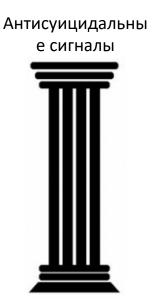
Интересное

- Тексты с мыслями о суициде модель сентимента предсказывала как нейтральные.
- Для антисуициадльной части хорошо подошли предсказания модели эмоций.
 - Joy
 - Surprise

Про инструкцию

Три столпа датасета

е сигналы





Состав

Основная часть

- Введение
- Как размечать
- Принципы разметки

Таблица классов

- Пресуицидальные сигналы
- Антисуицидальные сигналы

Принципы

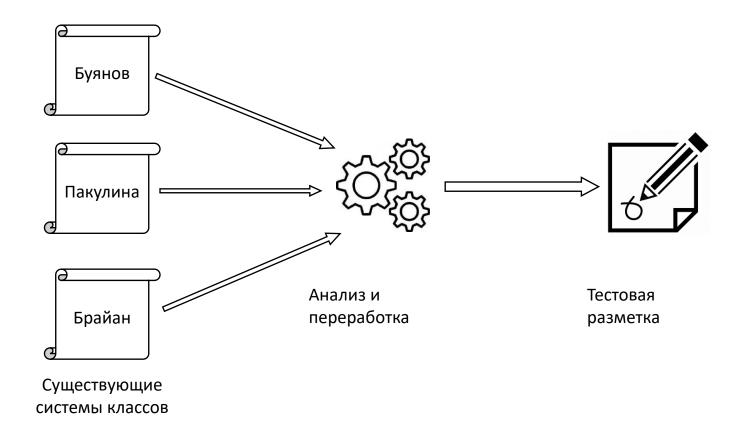
Содержание текста должно относиться к автору

- Я хочу сбежать из этого давящего внешнего мира к себе внутрь.
- У меня нет сил это терпеть.
- У него такая жесть дома происходит.

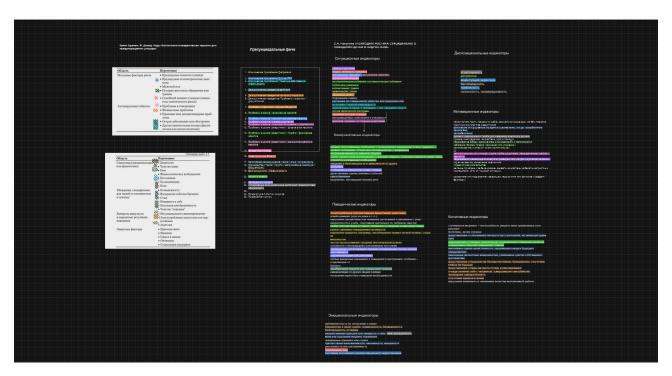
Не допустимо пытаться интерпретировать каким-либо образом тексты

- но не знала, чем и как все планы на будущее были связаны с ним, да вообще все было связано с ним любимые книги, любимая музыка
- я ненадолго отошел, а когда вернулся, она успела прочитать всю нашу откровенную переписку

Как создавали таблицы классов



Анализ существующих классификаций



Примеры сигналов

Пресуицидальны е сигналы	Клинические проявления/Депрессия
	Проблемы в семье/Сложные отношения с родственниками
	Смерть/Мысли о смерти
	Чувства/Одиночество, непонимание, изоляция, брошенность
Антисуицидальные сигналы	Наличие позитивных социальных связей
	Позитивные установки
	Наличие целей, планов на будущее, любимого дела
	Обращение за помощью

Схема тестовой разметки



Выявленные особенности

- Мультилейбл
 - Как объединять разметку?
 - Возьмем те классы, которые встретились минимум два раза мягкое голосование большинством.
 - Как считать степень согласия разметки?
 - С помощью Measuring agreement on set-valued items (MASI)

$$MASI = \frac{n(A \cap B)}{n(A \cup B)} * M$$

• Субъективность

Про разметку



Сравнение

Краудсорсинг

- Плюсы:
 - Большая аудитория
 - Есть из кого выбрать
 - Скорость разметки
 - Удобство оплаты
 - Конструктор интерфейсов разметки
- Минусы
 - Слабая вовлеченность исполнителей
 - Жульничество

Индивидуальные исполнители

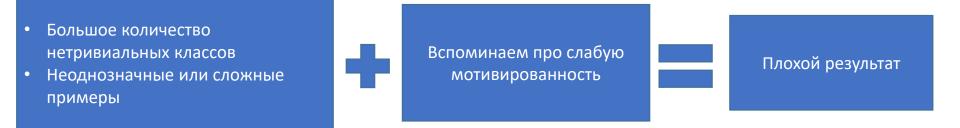
- Плюсы
 - Сильная вовлеченность
 - Минимизация жульничества
 - Быстрый цикл обратной связи
- Минусы
 - Затраты на поиск
 - Организация инфраструктуры
 - Дороже чем краудсорсинг



Главная проблема Яндекс.Заданий

- Они не работают с «физиками»-исполнителями
 - Два месяца организовывали доступ.
 - Выяснили, что оплата поступает одну-две недели.

Дополнительная проблема



Решили идти по пути индивидуальных исполнителей

- Дополнительные штрихи:
 - Большой опыт в создании инфраструктуры разметки
 - Есть доступ к серверу, на котором можно развернуться

Где искали разметчиков

- YOU DO 5 откликов, 3 человека, 2 соскочило
- *FREELANCE.RU* 30 откликов, 2 человека
- Профессиональные рекомендации 5 человек
- **Итого** 8 человек
 - 3 человека имеют опыт разметки
 - 1 человек имеет опыт работы психологом

Процесс найма и онбординга



Типичные примеры с ошибками при интервью

- Нарушение принципа наличия отношения к автору.
- Чрезмерная интерпретация
- Принятие рассуждения за факт
 - Все разметчики посчитали значимым текст «А если я не отдохну, то превращаюсь в ходящее зомби».

Полный процесс разметки



35

Где размечали



Интерфейс разметки

Я боюсь смотреть людям в глаза, я боюсь уверенно говорить с ними, отстаивать позицию.
Выберите сигналы
Перелевантный ⁽¹⁾ — Антисуицидальный сигнал ^[2] — Клинические проявления/Депрессия ^[8] — Клинические проявления/бессоница ^[4]
Клинические проявления/расстройство пищевого поведения (pnn) ^[S] ☐ Клинические проявления/Усталость, стресс, истощение ресурсов ^[6]
☑ Клинические проявления/тревожность, страх, фобии ^{гд} ☐ Клинические проявления/Другие психические расстройства [®]
Клиничесике проявления/физические заболевания, инвалидность [®] Клиничесике проявления/ попытка суицида в прошлом [®] Деструктивное поведение/Самоповреждение [®]
Деструктивное поведение/алкоголь и наркотики [№]
Проблемы в семье / сексуализированное насилие ^[6] ☐ Проблемы в семье / Распад семьи ^[6] ☐ Проблемы в семье / сложные отношения с родственниками ^[6]
Проблемы в семье/Трудности с беременностью, аборт, выкидыш ^{ия} □ Проблемы во внешнем мире/травля, физическое насилие [®]
Проблемы во внешнем мире/сексуализированное насилие ^ы □ Проблемы во внешнем мире/Несчастная любовь, проблемы с друзьями, сложности построения отношений ^М
Смерть/Смерть, несчастный случай или суицид близких [№] Смерть/Мысли о смерти [№] Смерть/Намерения самоубийства [®]
Чувства/Беспомощность, безвыходность, безнажежность, подавленность, отчаяние 🔽 Чувства/Негативное самоощущение, вина, стыд, никчемность, самобичевание
Чувства/Одиночество, тоска, грусть, непонимание, изоляция, брошенность 🖂 Чувства/Агрессия, гнев, обида, злость, раздражительность, ревность, несправедливость 🖂
Другое/Деструктивные установки [®] ☐ Другое/сталкинг [№] ☐ Другое/проблемы с профессиональным определением и реализацией [®]
Другое/Проблемы с деньгами (нищенство, долги) [№] Другое/Подражание кумиру в суцидальном поведении ^[m]
Комментарий

Где хранили



Контроль психологического состояния

- Поскольку тексты эмоционально заряженные, важно контролировать состояние разметчиков.
- Шкала Бека перед началом всей работы и в конце.
- Тест эмоционального состояние перед и после каждого блока.
- То самое вентилирование открытые эмпатичные интервью после каждого блока.

Интересное

- У некоторых разметчиков в начале была реакция на тексты.
- На середине пути все разметчики воспринимали тексты, как «работу».
- Некоторые разметчики посчитали, что работа позволила им лучше понять своих детей-подростков.

Качество

- Тестовую часть размечали с перекрытием в три человека.
- МІшики размечали сами по 185 примеров каждого блока параллельно разметке.
- Число несовпадений на всех контрольных заданиях:
 - для тренировочного набора составляет 14.55 процентов.
 - для тестового набора составляет 13.99 процентов.
- Антисуицидальная часть заметно хуже.

Статистика датасета

- Тренировочная часть 44 тыс. примеров (76,5%)
- Dev часть 4.5 тыс примеров (7,8%)
- Тестовая часть 9 тыс. Примеров (15,7%)

По классам:

- 33 пресуицидальных сигнала в 7 группах
- 8 антисуицидальных сигнала (в последствии 12)

Статистика датасета

Сигнал	N
Нерелевантный	6756
Смерть/мысли о смерти	6322
Чувства/негативное самоощущение, вина, стыд, никчемность, самобичевание	3049
Проблемы во внешнем мире/несчастная любовь, проблемы с друзьями, сложности	
построения отношений	2826
Чувства/беспомощность, безвыходность, безнажежность, отчаяние	2458
Проблемы в семье/сложные отношения с родственниками	2021
Защитные факторы/наличие позитивных социальных связей	1901
Чувства/душевное опустошение, подавленность, тоска, грусть	1804
Клинические проявления/депрессия	1666
Защитные факторы/позитивные установки	1459
Распределение текстов в тренировочной	

части

Нерелевантный Защитные факторы/наличие позитивных социальных связей Проблемы во внешнем мире/несчастная любовь, проблемы с друзьями, сложности построения отношений Чувства/негативное самоощущение, вина, стыд, никчемность, самобичевание	1651 1582
Защитные факторы/наличие позитивных социальных связей Проблемы во внешнем мире/несчастная любовь, проблемы с друзьями, сложности построения отношений Чувства/негативное самоощущение, вина, стыд, никчемность, самобичевание	1502
Проблемы во внешнем мире/несчастная любовь, проблемы с друзьями, сложности построения отношений Чувства/негативное самоощущение, вина, стыд, никчемность, самобичевание	1002
построения отношений Чувства/негативное самоощущение, вина, стыд, никчемность, самобичевание	576
Чувства/негативное самоощущение, вина, стыд, никчемность, самобичевание	
	530
	398
Клинические проявления/депрессия	392
Чувства/душевное опустошение, подавленность, тоска, грусть	323
Проблемы в семье/сложные отношения с родственниками	321
Чувства/одиночество, непонимание, изоляция, брошенность	281
Защитные факторы/позитивные воспоминания	276

Распределение текстов в тестовой

U2CTIA

Про модель

BERT как основа

- Позволяет кодировать контекст
- Богатая инфраструктура
 - Базовые модели
 - Фреймворки для обучения
 - Хорошая изученность
- (Теперь уже) небольшой размер высокая скорость обучения

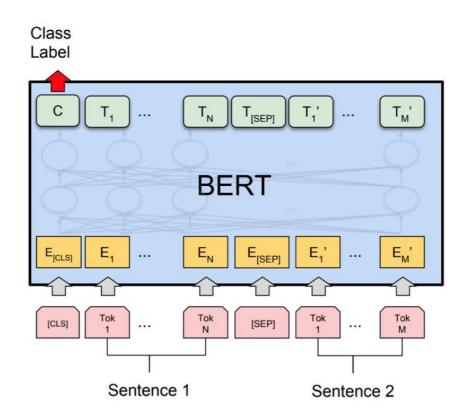
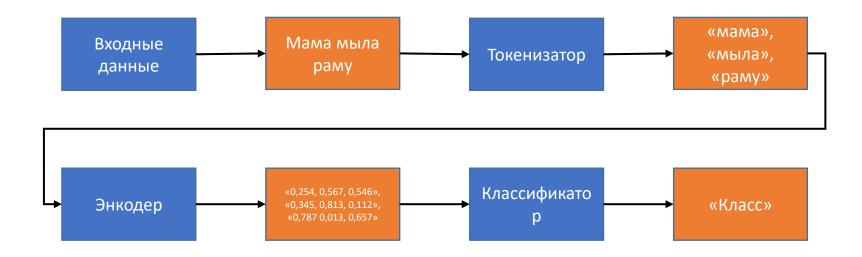


Схема работы



Результаты моделей

Наша цель: F1-macro больше 0,7 для обеих моделей

Как мы добились улучшения, читайте в девлоге по QR:



Модель	F1-macro
Пресуицидальная модель, ноябрь 2024	0,63
Антисуицидальная модель, ноябрь 2024	0,54
Пресуицидальная модель, февраль 2025	0,68 (+0,05)
Антисуицидальная модель, февраль 2025	0,71 (+0,16)

Качество моделей с «групповыми» классами

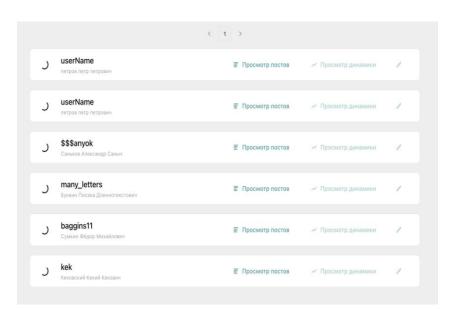
Планы

На текущий этап

- Довести систему до релиза
- Применить большие языковые модели для генерации/разметки данных
- Собрать сообщество неравнодушных людей

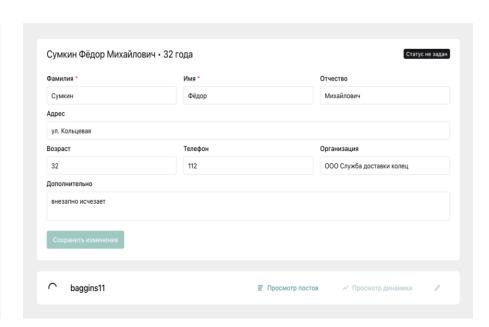
На будущее

- Совершенствовать датасет
- Внедрить систему заинтересованным организациям
- Научить систему предсказывать суицидальный статус
- Научить большую языковую модель обосновывать суицидальный статус



	11 со на странице * проверочный сомнительный	Сумкин Фёдор Михайлович • 32 года статус не вадин
		фильтр по атрибутам. \overline{Y}
22 марта 12:38 Э	Нулевой, раз уж мы программисты тут	
26 марта 07:28 тестовый × прове	Первый кусок текста зочный × +	
26 марта 08:23 7	Второй самый длинный проверочный от	трывок из того же текста
27 марта 12:28 проверочный × +	Третий мелкий	
28 марта 07:15 сомнительный ×	Добавленный позже четвертый	

<u>†</u> CSV-файл □		тестовая (4).csv		
Username *		Ссылка *		
Новый Пользователь добаллется впервые		Существущий Другие страницы пользователя уже есть в системе		
Фамилия •	имя •		Отчество	
Адрес				
Возраст	Телефон		Организация	
Дополнительно				



Выберите атрибуты ∨ Выберите скважность ∨ ■21/04/2025 - 21/04/2025

Выберите атрибуты для отображения

Контакты команды разработчиков датасета



Основной репозиторий



тг канал

СПАСИБО ЗА ВНИМАНИЕ!





Ведущий разработчик NLP IMP

MTS AI

buyanov.igor.o@yandex.ru



@Astromis